

Αλγοριθμικές Τεχνικές για Δεδομένα Ευρείας Κλίμακας

2° Φυλλάδιο Ασκήσεων

Προθεσμία υποβολής: 13/05/2026, 23:55

Εύρεση επικρατέστερου στοιχείου με χρήση CountMin (*Μονάδες: 8*)

Πρόκειται να δεχτούμε μία ακολουθία εντολών που αφορά το πλήθος εμφανίσεων συμβολοσειρών των 100 bits. Συγκεκριμένα, υποθέτουμε ότι για κάθε συμβολοσειρά υπάρχει ένας μετρητής που είναι αρχικοποιημένος στο 0, και κάθε εντολή που δεχόμαστε είναι της μορφής **update(s, c)**, η οποία προσθέτει στον μετρητή της συμβολοσειράς s την ακέραια τιμή c . Κατά την διάρκεια της ροής οι τιμές των μετρητών μπορούν να αυξομειώνονται αυθαίρετα, αλλά έχουμε την εγγύηση ότι στο τέλος της ροής θα υπάρχουν ακριβώς 1000 συμβολοσειρές με μη-μηδενικό μετρητή, όπου όλες τους θα έχουν την τιμή 10, εκτός από μία, που θα έχει την τιμή 100.

Ο σκοπός μας είναι να αναφέρουμε την συμβολοσειρά η οποία στο τέλος της ροής θα έχει την τιμή 100 στον μετρητή της. Το πρόβλημα είναι ότι η μνήμη που έχουμε στην διάθεσή μας δεν επαρκεί ώστε να έχουμε την πολυτέλεια να διατηρούμε έναν μετρητή για κάθε συμβολοσειρά που πρόκειται να εμφανιστεί στην ροή. Δηλαδή, μπορεί σε διάφορα σημεία της ροής να υπάρχουν δισεκατομμύρια συμβολοσειρές που έχουν μη-μηδενική τιμή στον μετρητή τους, και θα μπορούσε οποιαδήποτε από αυτές να είναι εκείνη που στο τέλος θα έχει την τιμή 100. Θα θέλαμε λοιπόν να πετύχουμε τον σκοπό μας χωρίς να συγκρατούμε τις συμβολοσειρές που εμφανίζονται.

Μία ιδέα για να λύσουμε αυτό το πρόβλημα είναι να βασιστούμε στην δομή CountMin. Περιγράψτε έναν αλγόριθμο που βασίζεται σε αυτήν την δομή, ώστε με πιθανότητα τουλάχιστον 99% να μπορούμε να αναφέρουμε σωστά την συμβολοσειρά που μας ενδιαφέρει στο τέλος της ροής. Προσπαθήστε να δώσετε μία λύση που χρησιμοποιεί συνολικά όσο το δυνατόν λιγότερα κελιά CountMin.

Έπειτα υλοποιήστε τον αλγόριθμο που προτείνετε, και ενσωματώστε ένα ενδεικτικό πείραμα για να επαληθεύσετε την λειτουργικότητά του. Συγκεκριμένα, αρκεί απλώς να φτιάξετε 1000 τυχαίες συμβολοσειρές των 100 bits, όπου οι πρώτες 999 θα εισαχθούν στην δομή με τιμή 10, και η τελευταία με τιμή 100. Στο τέλος, ο αλγόριθμος θα πρέπει να αναφέρει την συμβολοσειρά που έχει την τιμή 100 (αξιοποιώντας κατάλληλα τα δεδομένα που αποθηκεύτηκαν). Οι συναρτήσεις κατακερματισμού που θα χρησιμοποιήσετε θα πρέπει να προέρχονται από την οικογένεια Vec_p , για κάποιον πρώτο αριθμό p . (Συμβουλευτείτε τις σχετικές διαφάνειες που αφορούν αυτές τις συναρτήσεις κατακερματισμού. Ειδικότερα, κάθε συμβολοσειρά των 100 bits θα πρέπει ουσιαστικά να μετατρέπεται στο σύστημα αρίθμησης με βάση το p .)